

12. Distilling the Knowledge in a Neural Network

양상블에 포함된 지식을 하나의 단일 모델로 압축해 배포하기 쉽게 만들자!

Introduction

훈련할 때는 크고 복잡한 모델을 써도 괜찮지만, 배포(deployment) 단계에서는 **지연·속도·메모리 제한** 때문에 작은 모델이 필요하다. 하지만 작은 모델을 직접 학습시킨 모델은 큰 모델에 비해 성능이 떨어짐.

→ 큰 모델(또는 앙상블)의 지식을 작은 모델에 전이해보자

→ Distillation

: 큰 모델이 예측한 **soft targets**를 작은 모델의 훈련 목표로 사용

- soft targets는 정답뿐 아니라 오답 간 상대적 확률, 클래스 간 미세한 구조를 담고 있어 작은 모델이 큰 모델의 일반화 패턴을 학습하는 데 매우 효과적이다.

- **Temperature Softmax**

logits를 부드럽게 만들기 위해 softmax에 높은 temperature(T)를 적용

$T \uparrow \rightarrow$ 분포가 고르게 퍼짐 \rightarrow 클래스 간 관계가 더 잘 드러남

작은 모델은 이 soft한 분포를 학습하면서 큰 모델의 지식을 흡수한다.

- soft targets는 정답은 아니지만 비슷한 클래스에 적당한 확률을 주고, 따라서 클래스 간 구조를 효과적으로 전달할 수 있고 따라서 hard label만 학습하는 것보다 더 많은 정보를 담을 수 있다.

Distillation

- Softmax 출력층

$$q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

- 가장 단순한 형태 - transfer set에 대해 큰 모델이 높은 temperature의 softmax로 생성한 soft target을 사용하여 작은 모델(distilled model)을 훈련.
 - 작은 모델을 훈련할 때는 이 높은 temperature를 사용하지만, 훈련이 끝난 후에는 temperature를 1로 한다.
 - 가장 좋은 방법은 서로 다른 두 목적 함수의 가중 평균을 사용하는 것.

1. soft targets와의 cross-entropy

- 큰 모델의 soft targets 생성에 사용된 것과 동일한 높은 temperature를 작은 모델의 softmax에도 적용하여 계산

2. 정답 레이블과의 cross-entropy

- temperature = 1을 사용

→ 실험 결과, 두 번째 목적 함수의 가중치를 훨씬 낮게 주는 것이 가장 좋은 성능을 보임

- soft target이 생성하는 gradient의 크기는 $1/T^2$ 비율로 작아지므로, hard target과 soft target을 함께 사용할 경우 gradient를 T^2 로 곱해주는 것이 중요하다. 이렇게 하면 temperature를 조절해도 두 손실의 상대적 기여도가 유지된다.

Matching logits is a special case of distillation

transfer set의 각 sample은 작은 모델의 logit z_i 에 대해서 cross-entropy gradient dC / dz_i 를 제공

- 큰 모델의 logits v_i , soft target 확률 p_i 를 생성한다고 할 때 gradient:

$$\frac{\partial C}{\partial z_i} = \frac{1}{T} (q_i - p_i) = \frac{1}{T} \left(\frac{e^{z_i/T}}{\sum_j e^{z_j/T}} - \frac{e^{v_i/T}}{\sum_j e^{v_j/T}} \right)$$

- 만약 temperature가 logits의 크기보다 훨씬 크다면:

$$\frac{\partial C}{\partial z_i} \approx \frac{1}{T} \left(\frac{1 + z_i/T}{N + \sum_j z_j/T} - \frac{1 + v_i/T}{N + \sum_j v_j/T} \right)$$

logits가 transfer case마다 zero-mean 되도록

$$\sum_j z_j = \sum_j v_j = 0$$

를 가정하면 위 식은 단순화되어:

$$\frac{\partial C}{\partial z_i} \approx \frac{1}{NT^2} (z_i - v_i)$$

→ high-temperature limit에서는 distillation이 사실상

$$\frac{1}{2} (z_i - v_i)^2$$

를 최소화하는것과 동일하다.

Preliminary experiments on MNIST

MNIST 실험 결과

- Distillation은 작은 모델의 성능을 크게 끌어올림
 - 큰 모델: 67 errors
 - 작은 모델(정규화 없음): 146 errors
 - 작은 모델 + soft targets 학습: 74 errors
 - 작은 모델이 큰 모델의 일반화 능력을 상당 부분 전이 받음.
- Temperature는 작은 모델의 크기에 따라 최적값이 달라짐

- 모델이 클 때(≥ 300 units) $\rightarrow T \geq 8$ 이면 거의 동일
- 모델이 매우 작을 때(≈ 30 units) $\rightarrow T = 2.5 \sim 4$ 가 최적
 \rightarrow 작은 모델일수록 너무 크거나 작은 T 는 오히려 해가 됨.
- Transfer set에서 특정 클래스(예: '3')를 완전히 제거해도 generalization 가능
 - '3'을 훈련에서 한 번도 보지 않아도
 - bias만 조정하면 test '3'의 ****98.6%****를 정확히 인식
 \rightarrow Distillation은 "클래스 간 구조적 정보"를 전이시키기 때문에, unseen class도 어느 정도 인식 가능.
- Label bias 조정만으로 성능이 크게 향상됨
 - mnist 7/8만 보고도 전체 테스트 오류를 47.3% \rightarrow 13.2%로 감소
 \rightarrow Teacher model의 soft target이 클래스 간 상대적 관계를 잘 전달하기 때문.

Experiments on speech recognition

자동 음성 인식(ASR)에 사용되는 심층 신경망(DNN) 음향 모델에 대해 앙상블링의 효과를 조사

\rightarrow distillation 전략 사용 시, 동일한 훈련 데이터를 사용해 개별적으로 학습된 여러 모델의 앙상블 대신, **단일 모델에 앙상블의 효과를 증류하는 결과를 낳으며**, 동일한 크기의 모델을 직접 학습한 경우보다 훨씬 더 좋은 성능을 발휘한다.

- 최신 ASR 시스템:

일반적으로 DNN을 사용하여 (짧은) 시간적 컨텍스트의 특징을 파형에서 추출하고, 이를 HMM(Hidden Markov Model)의 이산 상태에 대한 확률 분포로 매핑함

- DNN을 훈련할 때 언어 모델의 영향을 고려하기 위해 모든 가능한 경로에 대해 주변화(marginalization)하는 것이 가능(그리고 바람직)하지만,
- 일반적으로는 강제 정렬(forced alignment)된 정답 HMM 상태에 대해 frame-by-frame 분류를 수행하도록 cross entropy를 최소화하여 훈련한다.

$$\theta = \arg \max_{\theta'} P(h_t | s_t; \theta')$$

실험

- 동일한 아키텍처와 훈련 절차를 사용하여 서로 다른 초기 파라미터 값으로 10개의 모델을 훈련
- distillation에는 온도 **1, 2, 5, 10**을 실험했으며, hard targets의 cross entropy에는 가중치 0.5 사용
 - 10개 모델 앙상블을 사용할 때 얻어지는 frame classification accuracy 개선의 **80% 이상이 distilled model로 성공적으로 전이되었다.**

결과

System	Test Frame Accuracy	WER
Baseline	58.9%	10.9%
10xEnsemble	61.1%	10.7%
Distilled Single model	60.8%	10.7%

→ distillation된 단일 모델이 soft targets를 생성한 10개 모델 앙상블의 평균 결과와 거의 비슷한 성능을 낸다.

Training ensembles of specialists on very big datasets

앙상블에 대한 또 다른 반론 = 개별 모델이 큰 신경망이고 데이터셋이 매우 큰 경우, 비록 병렬화가 쉽더라도 훈련 시 필요한 계산량이 너무 많아진다.

→ 클래스 중 서로 혼동되기 쉬운(subset) 부분만을 각 specialist 모델이 담당하도록 하는 전략으로 앙상블 학습에 필요한 총 계산량을 줄일 수 있음을 보여줌

The JFT dataset

Google 내부 데이터셋으로, 1억 개의 라벨링된 이미지와 15,000개의 라벨을 포함. JFT baseline 모델은 6개월 동안 다수의 코어에서 **비동기적 스토캐스틱 경사하강 (asynchronous SGD)** 으로 학습된 대규모 CNN

사용된 병렬화

- 데이터 병렬(data parallelism):

- 여러 replica가 서로 다른 minibatch를 처리하며, 각 replica는 자신의 gradient를 공유된 parameter server로 전송
- parameter server는 gradient를 모아 업데이트된 파라미터를 다시 replicas로 전송

- **모델 병렬(model parallelism):**

- 거대한 네트워크를 여러 코어로 분할하여 각 subset의 뉴런을 각 코어에 배치

→ 앙상블 학습은 이 두 종류의 병렬화 위에 또 하나의 병렬 계층(third type of parallelism)을 더 얹는 것과 같다.

JFT 1: Tea party; Easter; Bridal shower; Baby shower; Easter Bunny; ...
JFT 2: Bridge; Cable-stayed bridge; Suspension bridge; Viaduct; Chimney; ...
JFT 3: Toyota Corolla E100; Opel Signum; Opel Astra; Mazda Familia; ...

Specialist Models

특정 specialist model은 자신이 신경 쓰지 않는 클래스들은 모두 하나의 "dustbin class"로 합쳐 softmax 규모를 크게 줄일 수 있다.

Specialist 학습 방법

- Specialist는 generalist model의 가중치로 초기화
- 자신의 domain에서 온 예시 50%, 일반 training set에서 random sampling된 50%로 학습
- Specialist는 oversampled된 클래스가 있기 때문에, dustbin class에 대한 예측 logit을 보정해 줘야 한다.

Assigning classes to specialists

specialist를 위한 object category 그룹을 만들기 위해, generalist model이 자주 혼동하는 클래스들에 집중

- 정답 라벨을 사용하지 않기 위해, generalist model의 예측 covariance matrix를 사용하여 clustering을 적용

절차

- covariance matrix의 column에 대해 online K-means 알고리즘 적용

- Table 2와 같은 reasonable clusters 생성
- 여러 알고리즘을 시도했지만 유사한 결과 도출됨

Performing inference with ensembles of specialists

specialist 모델을 distillation하기 전에, specialist를 포함하는 앙상블이 얼마나 잘 작동하는지 먼저 평가

1. generalist model이 예측한 top-n 클래스를 선택 (n=1)
2. 그 top-1 클래스와 교집합을 갖는 specialist 모델들로 active set A_k 구성.
3. 다음 KL-divergence를 최소화하는 전체 분포 q 계산

$$KL(p^g, q) + \sum_{m \in A_k} KL(p^m, q)$$

Result

훈련 완료된 generalist model에서 시작하여, specialist 모델들은 매우 빠르게 훈련시킬 수 있다.(몇 일)-?

- 각 specialist는 독립적으로 학습 가능

System	Conditional Test Accuracy	Test Accuracy
Baseline	43.1%	25.0%
+ 61 Specialist models	45.9%	26.1%

→ Specialist 추가로 top-1 accuracy 4.4%p 증가

# of specialists covering	# of test examples	delta in top1 correct	relative accuracy change
0	350037	0	0.0%
1	141993	+1421	+3.4%
2	67161	+1572	+7.4%
3	38801	+1124	+8.8%
4	26298	+835	+10.5%
5	16474	+561	+11.1%
6	10682	+362	+11.3%
7	7376	+232	+12.8%
8	4703	+182	+13.6%
9	4706	+208	+16.6%
10 or more	9082	+324	+14.1%

Specialist가 커버하는 경우 top-1 accuracy 변화

→ Specialist가 많이 관여할수록 정확도 개선 폭이 커지고, Specialist 모델들이 병렬학습이 가능하므로 규모 확장이 쉬움

Soft Targets as Regularizers

단일 하드 타겟으로는 결코 담을 수 없는 많은 유용한 정보를 소프트 타겟은 담을 수 있음

System & training set	Train Frame Accuracy	Test Frame Accuracy
Baseline (100% of training set)	63.4%	58.9%
Baseline (3% of training set)	67.3%	44.5%
Soft Targets (3% of training set)	65.4%	57.0%

→ 데이터의 단 3% (약 2,000만 개 예시)만을 사용해 baseline 모델을 하드 타겟으로 학습하면 심각한 과적합이 발생한다.

→ 동일한 모델을 소프트 타겟으로 학습하면 전체 학습 데이터에서 얻을 수 있는 정보의 거의 대부분을 회복할 수 있었음. 조기 종료도 없이.

⇒ **소프트 타겟이 전체 데이터를 사용해 학습된 모델이 발견한 규칙성을 다른 모델에게 전달하는 데 매우 효과적이다.**

Using soft targets to prevent specialists from overfitting

JFT 데이터셋 실험에서 사용한 specialist 모델들은 자신이 담당하지 않는 모든 클래스를 단일 dustbin 클래스에 넣음

→ specialist는 자신의 special class들이 매우 많이 포함된 데이터로 학습되는데, 따라서 실질적인 훈련 데이터셋 크기는 매우 작으며, 그 special class들에 **심하게 과적합**되기 쉬움.

이를 해결하기 위한 방법으로 soft target 을 이용할 수 있음.

- specialist 모델을 generalist 모델의 가중치로 초기화한
- 그 specialist에게 non-special classes에 대한 soft targets를 함께 제공하여 학습 시키면,
- specialist는 non-special 클래스에 대한 지식을 거의 그대로 유지할 수 있다.

Relationship to Mixtures of Experts

데이터의 하위 집합에 대해 학습된 specialist를 사용하는 것은 mixture of experts와 어느 정도 유사함

- Mixture of experts: 게이팅 네트워크(gating network)를 사용하여 각 예시를 어떤 expert에게 할당할지 결정하는 확률을 계산
 - experts는 자신에게 할당된 예시를 처리하도록 학습
 - 게이팅 네트워크는 각 예시에 대해 어떤 expert를 사용할지 학습
 - 문제점
 1. 각 expert가 보는 weighted training set이 모든 다른 expert에 따라 계속 변함
 2. 게이팅 네트워크가 동일한 예시에 대해 여러 expert의 성능을 비교하고 그에 따라 확률을 수정해야 함
- mixture of experts는 실제로 가장 유용할 만한 상황—즉, 엄청난 규모의 데이터셋에서 클래스 간 명확한 subset 구조가 있는 경우—에서도 거의 사용되지 않는다.
- specialist 여러 개를 병렬로 학습하는 것 이 훨씬 낫다.