

# [week5] BERT

## BERT

### 1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가  
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

- **BERT**라는 새로운 언어 표현 모델을 제안
- BERT는 왼쪽과 오른쪽 문맥을 모두 고려하여
  - 딥 양방향 표현(deep bidirectional representations) 을 사전 학습(pre-train)하고
  - 이를 다양한 자연어처리(NLP) 작업에 쉽게 fine-tuning 할 수 있도록 설계됨.
- 기존 사전 학습된 언어 모델들은 주로 한 방향으로만 문맥을 고려
  - 문장의 양쪽 맥락을 동시에 고려할 수 없다는 한계가 有
  - 문장 수준과 토큰 수준 작업에서는 양방향 문맥 이해가 매우 중요

### 논문이 다루는 분야

- 자연어처리 (NLP)
- 언어 모델링(language modeling)
- 전이 학습(transfer learning)
- 텍스트 이해(text understanding)

### 해당 task에서 기존 연구 한계점

- feature-based 방법: 양방향 문맥을 concatenation
  - fine-tuning 기반 방법: 왼쪽-오른쪽 방향성만 학습 / 문장 전체의 양방향 정보를 제대로 반영X
- ⇒ 기존 방법은 구조적으로 양방향 문맥을 깊게 고려하는 데 한계가 있었음.

### 논문의 contributions

- **Masked Language Model (MLM)** 을 통해 진정한 딥 양방향 사전학습을 가능하게 함
- 다양한 NLP 작업에서 복잡한 task-specific 구조 없이 fine-tuning만으로 최고 성능 달성
- **11개 NLP** 벤치마크에서 새로운 SOTA 기록 달성

## 2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가  
제안 방법의 차별성을 어떻게 표현하고 있는가

### 2.1. Unsupervised Feature-based Approaches

- 전통적 단어 임베딩연구 (ex. Word2Vec, GloVe)
- **ELMo**: 왼쪽-오른쪽 별도 학습 후 결과를 결합하여 문맥 정보를 반영. 하지만 깊은 양방향 표현은 아님.

### 2.2. Unsupervised Fine-tuning Approaches

- **OpenAI GPT**: 좌측 맥락만 보는 Transformer로 전체 문장을 예측하는 방식.
- **ULMFiT**: fine-tuning으로 downstream task를 학습.

### 2.3. Transfer Learning from Supervised Data

- Supervised task(ex. 자연어 추론 데이터)를 이용하여 사전학습
- 컴퓨터 비전에서는 ImageNet pre-training 후 fine-tuning하는 접근법이 일반적.

### 2.4. 기존 연구와 BERT의 차별성

- BERT는 딥 양방향 사전학습이 가능하도록  
→ Masked Language Model(MLM) 과 Next Sentence Prediction(NSP) 을 사용.
- 사전학습-미세조정(fine-tuning) 일관된 구조 사용.
- 단순히 feature를 추출하는 데 그치지 않고, 모든 파라미터를 통째로 **fine-tuning**.

## 3. 제안 방법론



- Introduction에서 언급된 내용과 동일하게 작성되어 있는가
- Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
- 제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

## Main Idea

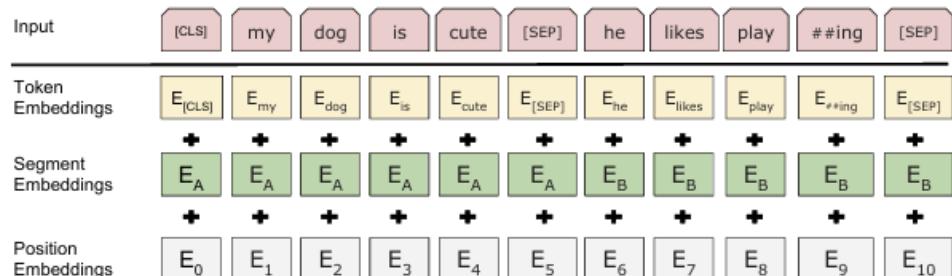
- 입력 문장을 WordPiece로 잘라서 token sequence로 변환
- special token CLS와 SEP를 추가.
- 입력은 단일 문장 또는 문장 쌍 모두 가능.

## Model Architecture

- Transformer Encoder** 구조 기반.
- 두 모델 구조
  - : BERTBASE (12-layer, 768-hidden, 12-head)
  - : BERTLARGE (24-layer, 1024-hidden, 16-head)

## Input/Output Representations

- 입력 임베딩: Token Embedding + Segment Embedding + Position Embedding
- CLS 벡터는 전체 시퀀스를 대표하는 표현으로 사용



## Pre-training BERT

### Task 1: Masked LM

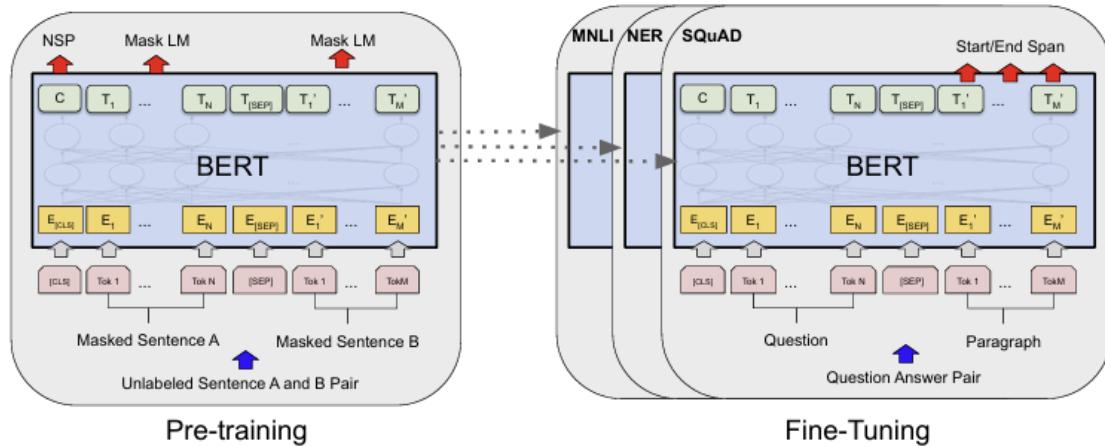
- 입력 토큰 중 15%를 무작위로 마스킹, 주변 문맥을 기반으로 해당 토큰 예측
- denoising autoencoder와 유사 BUT, 전체 문장이 아니라 마스킹된 부분만 예측

### Task 2: Next Sentence Prediction (NSP)

- 문장 A 다음에 문장 B가 실제로 이어지는지 여부를 이진 분류(IsNext / NotNext)로 예측

## Fine-tuning BERT

- 사전학습된 BERT에 task-specific output layer만 추가.
- 모든 downstream 작업(text classification, QA 등)에서 같은 구조 사용.



## Contribution

- Masked Language Model (MLM) 사용하여 deep bidirectional pre-training 을 가능하게 함
- 문장 쌍 간의 관계 학습을 모델링하기 위해 Next Sentence Prediction (NSP) 도입
- Pre-training과 Fine-tuning 과정에서 구조 일관성 유지 → 전이학습(transfer learning) 단순화
  - Task-specific output layer만 추가, 전체 모델을 end-to-end로 미세조정 가능하게 함
- 다양한 Downstream Task를 하나의 통합 모델로 처리
- Feature-based 접근과 Fine-tuning 접근 모두에서 뛰어난 효과
  - 전체 모델을 fine-tuning 하는 방식 외에도, 특정 hidden layer feature를 뽑아서 별도 task-specific 모델에 활용해도 높은 성능을 보임.

## 4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

## 4.1. GLUE

- 다양한 문장 수준/문장 쌍 수준 NLU tasks 집합.
- BERTBASE와 BERTLARGE 모두 GLUE에서 기존 모델보다 높은 평균 정확도를 기록함.
- [Dataset](#)
  - GLUE benchmark (문장 분류, 문장 쌍 분류 등 다양한 NLU 과제 모음)
    - MNLI, QQP, QNLI, SST-2, CoLA, STS-B, MRPC, RTE 포함
- [Baseline](#)
  - Pre-OpenAI SOTA 모델 (BiLSTM+ELMo 등)
  - OpenAI GPT
- [결과](#)
  - BERTBASE: 기존 최고 모델(OpenAI GPT) 대비 평균 +4.5% 성능 향상
  - BERTLARGE: 평균 +7.0% 성능 향상
  - 특히, MNLI task에서 +4.6% 절대 정확도 개선
  - GLUE leaderboard 기준 BERTLARGE: 80.5점 → OpenAI GPT 대비 대폭 향상

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT <sub>BASE</sub>	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT <sub>LARGE</sub>	<b>86.7/85.9</b>	<b>72.1</b>	<b>92.7</b>	<b>94.9</b>	<b>60.5</b>	<b>86.5</b>	<b>89.3</b>	<b>70.1</b>	<b>82.1</b>

## 4.2. SQuAD v1.1

- 질문과 단락을 받아 정답이 포함된 스패닝 예측.
- BERT가 SQuAD v1.1 단일 모델 기준 최고 성능을 기록함.
- [Dataset](#)
  - 100k개 이상의 crowd-sourced 질문-답변 쌍 (Wikipedia 기반)

- Baseline
  - BiDAF+ELMo (Single model)
  - R.M. Reader (Ensemble)
- 결과
  - BERTLARGE (Single model): F1 91.1% (TriviaQA 없이도 90.9%)
  - BERTLARGE (Ensemble): F1 93.2% → 기존 최상위 시스템 대비 +1.5 F1 개선
  - Single model만으로도 기존 SQuAD leaderboard ensemble을 초과

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	-	-	82.3	91.2
#1 Ensemble - nlnet	-	-	86.0	91.7
#2 Ensemble - QANet	-	-	84.5	90.5
Published				
BiDAF+ELMo (Single)	-	85.6	-	85.8
R.M. Reader (Ensemble)	81.2	87.9	82.3	88.5
Ours				
BERT <sub>BASE</sub> (Single)	80.8	88.5	-	-
BERT <sub>LARGE</sub> (Single)	84.1	90.9	-	-
BERT <sub>LARGE</sub> (Ensemble)	85.8	91.8	-	-
BERT <sub>LARGE</sub> (Sgl.+TriviaQA)	<b>84.2</b>	<b>91.1</b>	<b>85.1</b>	<b>91.8</b>
BERT <sub>LARGE</sub> (Ens.+TriviaQA)	<b>86.2</b>	<b>92.2</b>	<b>87.4</b>	<b>93.2</b>

### 4.3. SQuAD v2.0

- 답이 없는 경우도 허용하는 SQuAD 확장 버전.
- no-answer를 CLS 토큰 위치로 모델링하여, 답이 없을 때를 잘 분류할 수 있도록 학습.
- Dataset
  - 답변이 존재하지 않는 경우를 포함한 질문-답변 쌍
- Baseline
  - MIR-MRC (F-Net)
  - nlnet
  - Human upper bound도 비교
- 결과
  - BERTLARGE (Single model):
    - Dev set: EM 80.0, F1 83.1

- Test set: EM 80.0, F1 83.1
  - 이전 최고 성능 대비 +5.1 F1 개선
  - 인간 성능(약 89.5 F1)에는 미치지 못하지만, 기존 모델들 대비 큰 도약

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	86.3	89.0	86.9	89.5
#1 Single - MIR-MRC (F-Net)	-	-	74.8	78.0
#2 Single - nlnet	-	-	74.2	77.1
Published				
unet (Ensemble)	-	-	71.4	74.9
SLQA+ (Single)	-	-	71.4	74.4
Ours				
BERT <sub>LARGE</sub> (Single)	78.7	81.9	80.0	83.1

## 4.4. SWAG

- 주어진 문장에 가장 자연스러운 다음 문장을 선택하는 상식추론 데이터셋.
- BERT가 SWAG에서도 기존 모델 대비 크게 성능 향상.
- [Dataset](#)
  - 113k개 sentence-pair completion 예제 (상식적 추론 문제)
- [Baseline](#)
  - ESIM+ELMo
  - OpenAI GPT
- [결과](#)
  - BERTLARGE:
    - Dev accuracy: 86.6%
    - Test accuracy: 86.3%
  - OpenAI GPT 대비 +8.3% 향상
  - 기존 최고 baseline (ESIM+ELMo) 대비 +27.1% 절대 향상

System	Dev	Test
ESIM+GloVe	51.9	52.7
ESIM+ELMo	59.1	59.2
OpenAI GPT	-	78.0
BERT <sub>BASE</sub>	81.6	-
BERT <sub>LARGE</sub>	<b>86.6</b>	<b>86.3</b>
Human (expert) <sup>†</sup>	-	85.0
Human (5 annotations) <sup>†</sup>	-	88.0

## 5. Ablation Studies

- Ablation Study는 모델의 성능에 가장 큰 영향을 미치는 요소를 찾기 위해
- 모델의 구성요소 및 feature들을 단계적으로 제거하거나 변경해가며 성능의 변화를 관찰하는 방법
- 모델의 핵심적인 구성요소와 하이퍼파라미터 등을 파악할 수 있습니다.

<https://modulabs.co.kr/blog/ablation-study>

### 5.1. Effect of Pre-training Tasks

- NSP를 제거하거나, 왼쪽-오른쪽 방향만 학습하면 성능이 상당히 하락
- 특히 QNLI, MNLI, SQuAD와 같은 문장 관계 추론 작업에서 NSP의 중요성이 확인됨.
- **Dataset**
  - MNLI, QNLI, MRPC, SST-2, SQuAD v1.1 (BERT 논문에서 실험한 대표적 downstream tasks)
- **Baseline**
  - Full BERTBASE (MLM + NSP 적용)
  - 변형된 모델들:
    - No NSP (Next Sentence Prediction 제거)
    - LTR & No NSP (Left-to-Right만 학습, NSP도 제거 — OpenAI GPT에 가까운 설정)
    - 추가로 BiLSTM을 LTR모델 위에 얹은 버전도 실험
- **결과**

- No NSP:
  - 특히 문장쌍 관계(task)에서 성능 하락 (ex. QNLI, MNLI).
  - SQuAD에서도 성능 약간 감소.
- LTR & No NSP:
  - 모든 task에서 큰 성능 저하 발생.
  - 특히 MRPC(문장 유사성)와 SQuAD(질문응답)에서 성능 급락.
- LTR & No NSP + BiLSTM 추가:
  - 일부 성능 회복했지만 여전히 양방향 사전학습 성능에는 미치지 못함.

Tasks	Dev Set				
	MNLI-m (Acc)	QNLI (Acc)	MRPC (Acc)	SST-2 (Acc)	SQuAD (F1)
BERT <sub>BASE</sub>	84.4	88.4	86.7	92.7	88.5
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP	82.1	84.3	77.5	92.1	77.8
+ BiLSTM	82.1	84.1	75.7	91.6	84.9

## 5.2. Effect of Model Size

- 더 큰 모델(BERTLARGE)이 항상 더 높은 성능을 보임.
- 작은 데이터셋(MRPC)에서도 큰 모델의 이점이 뚜렷하게 나타남.
- [Dataset](#)
  - MNLI, QNLI, MRPC, SST-2 (대표적인 GLUE 과제)
- [Baseline](#)
  - BERT 모델 크기 변화 실험:
    - (L=3, H=768, A=12)
    - (L=6, H=768, A=3 또는 12)
    - (L=12, H=768, A=12) → BERTBASE 수준
    - (L=12, H=1024, A=16)
    - (L=24, H=1024, A=16) → BERTLARGE 수준
- [결과](#)
  - 모델 크기(L, H, A)가 커질수록 모든 task에서 성능 지속적 증가.
  - **MNLI, MRPC** (데이터 수 적은 task)에서도 큰 모델이 더 좋은 성능.

- Language modeling perplexity (LM ppl)도 모델이 클수록 낮아짐.

#L	#H	#A	Dev Set Accuracy			
			LM (ppl)	MNLI-m	MRPC	SST-2
3	768	12	5.84	77.9	79.8	88.4
6	768	3	5.24	80.6	82.2	90.7
6	768	12	4.68	81.9	84.8	91.3
12	768	12	3.99	84.4	86.7	92.9
12	1024	16	3.54	85.7	86.9	93.3
24	1024	16	3.23	86.6	87.8	93.7

### 5.3. Feature-based Approach with BERT

- Fine-tuning 없이 BERT의 hidden layer 출력을 feature로 활용할 경우에도 매우 좋은 결과.
- 특히 마지막 네 개 hidden layer를 concat하는 방식이 가장 우수.
- [Dataset](#)
  - CoNLL-2003 Named Entity Recognition (NER) Task
- [Baseline](#)
  - Fine-tuning 방식 (BERT 전체 미세조정)
  - Feature-based 방식 (BERT의 특정 layer feature만 뽑아서 사용)
- [결과](#)
  - Fine-tuning (BERTLARGE): Test F1 92.8
  - Feature-based (BERTBASE 기준):
    - Single layer 사용: 약간 낮은 성능 (ex. Last hidden 94.9 Dev F1)
    - Top 4 hidden layers concat: Dev F1 96.1 (Fine-tuning 대비 0.3점 차이)
  - 전체적으로, feature extraction만으로도 기존 SOTA 모델들과 비슷하거나 더 좋은 성능.

System	Dev F1	Test F1
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark et al., 2018)	-	92.6
CSE (Akbik et al., 2018)	-	<b>93.1</b>
Fine-tuning approach		
BERT <sub>LARGE</sub>	96.6	92.8
BERT <sub>BASE</sub>	96.4	92.4
Feature-based approach (BERT <sub>BASE</sub> )		
Embeddings	91.0	-
Second-to-Last Hidden	95.6	-
Last Hidden	94.9	-
Weighted Sum Last Four Hidden	95.9	-
Concat Last Four Hidden	96.1	-
Weighted Sum All 12 Layers	95.5	-

## 6. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- 언어 모델 기반 전이학습이 NLP 전반에 중요함.
- 딥 양방향 Transformer를 통한 사전학습이 매우 효과적임 (BERT)
- 다양한 NLP task에 대해 별도의 아키텍처 수정 없이 뛰어난 성능을 발휘할 수 있음.

## 교재 예습

- BERT
- 트랜스포머 인코더 기반

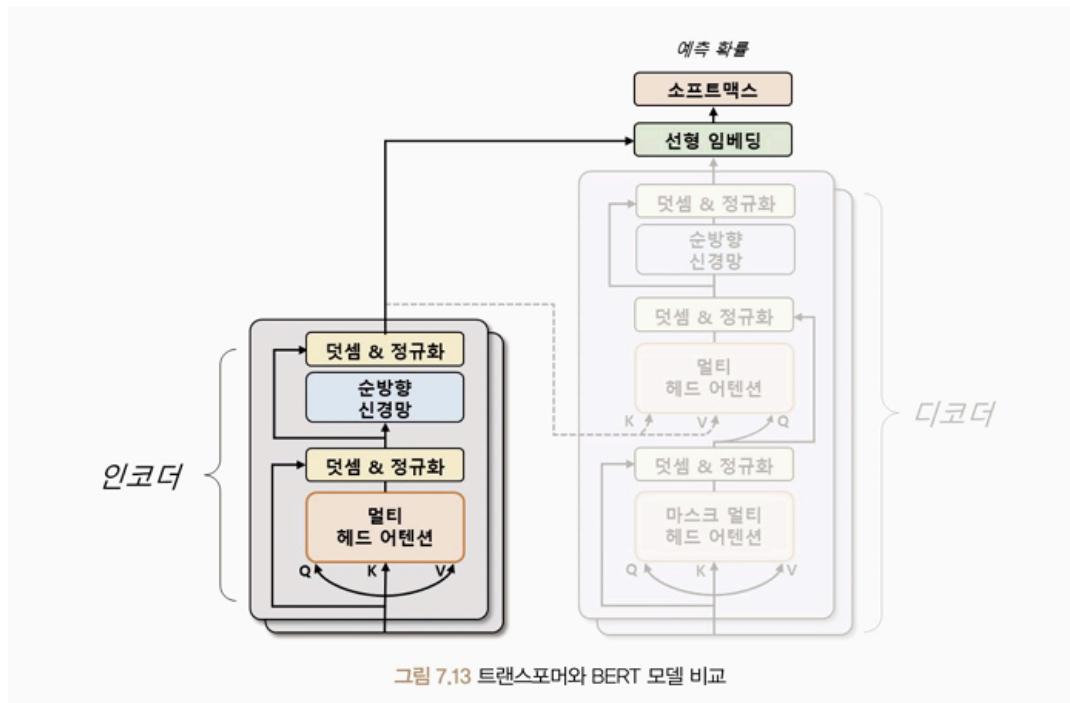


그림 7.13 트랜스포머와 BERT 모델 비교

- 양방향 인코더를 사용하는 자연어 처리 모델
  - 입력 시퀀스를 양쪽 방향에서 처리 → 이전, 이후 단어 모두 참조하여 의미, 맥락 해석
- 대규모 데이터 사용 → 전이 학습에 주로 활용
- 사전학습 방법
  1. MLM
    - 일부 단어를 마스킹하고 해당 단어를 예측하는 방식
    - 누락된 단어 추론하는 능력, 문장 전체 의미를 이해하는 능력 향상
  2. NSP
    - 두 개의 문장 주어졌을 때, 한 문장이 다른 문장의 다음에 오는 문장인지 판단
    - 두 문장 간 관계 학습, 문장 간 의미적인 유사성 파악
- 사용되는 토큰
  - [CLS] 입력 문장의 시작 부분에 추가. 문장 분류 작업을 위한 정보 제공
  - [SEP] 두 개 이상의 문장을 구분하기 위해 사용
  - [MASK] 임의로 선택된 단어를 가리키는 토큰
- 임베딩 구조와 손실 함수

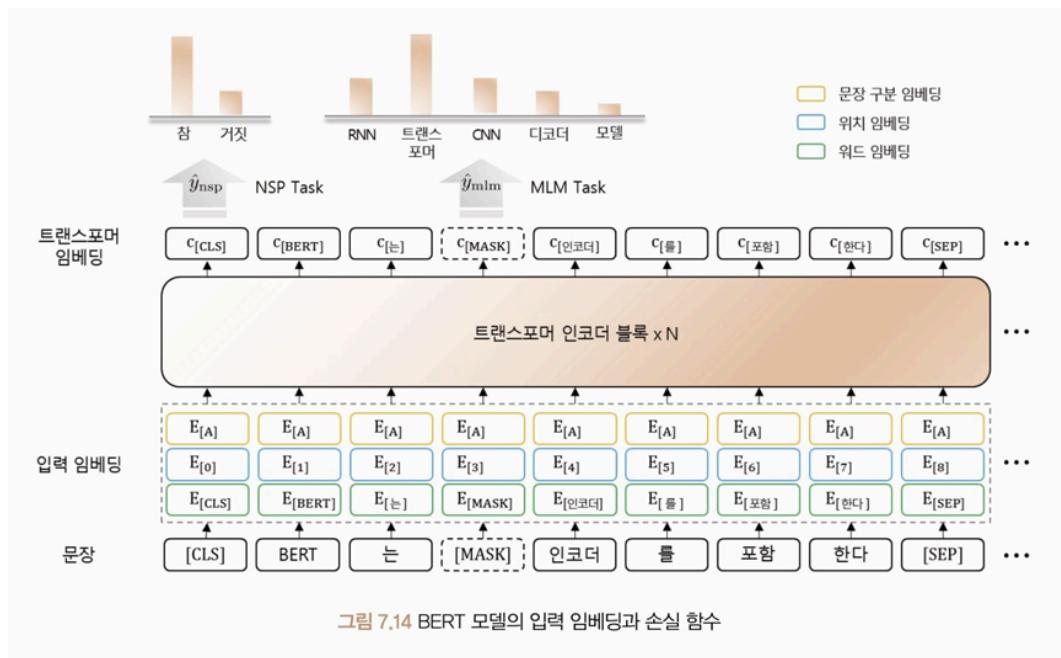


그림 7.14 BERT 모델의 입력 임베딩과 순서 험수

- 사전학습 후 미세조정 기법으로 다양한 자연어 처리 작업에 적용 가능