



# [week12] 논문리뷰

## Distilling the Knowledge in a Neural Network

### 1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

### 2. 제안 방법론

### 3. Related Work

### 4. 실험 및 결과

### 5. 결론 (배운점)

## Distilling the Knowledge in a Neural Network

### 1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가  
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

### 논문이 다루는 분야

- model compression
- knowledge transfer
- Knowledge Distillation
- 주로 적용한 task = supervised 분류 문제 전반
  - MNIST 이미지 분류
  - 대규모 음성 인식용 음향 모델
  - 초대형 이미지 데이터셋(JFT) 분류

## 해당 task에서 기존 연구 한계점

### 1. 앙상블 / 대형 모델의 실용성 한계

- 앙상블이나 매우 큰 네트워크는 학습 시에는 좋지만, 파라미터 수가 많고 메모리/연산량이 크고 응답 시간이 느려 실제 서비스(모바일, 온라인 서빙 등)에 쓰기에는 너무 비싸다.

### 2. 기존 model compression(=logit matching) 방식의 제한

- 앙상블의 logit이나 예측값을 그대로 맞추는 식의 모델 압축은 존재했지만, “왜 잘 되는지”, “어떤 형태의 정보가 중요한지”를 체계적으로 해석할 수 있는 일반적인 프레임워크가 부족했다
- 특히 softmax의 온도(temperature)를 조절하면서 어떤 온도에서 어떤 정보(클래스 간 유사도 구조)가 가장 잘 드러나는지 logit matching이 어떤 경우에 자연스럽게 나오는지를 이론적으로 연결해 설명해주지 못했다

### 3. 작은 모델을 직접 hard label로만 학습할 때의 한계

- 작은 네트워크를 같은 데이터, 같은 hard label만으로 학습하면 대형 모델/앙상블이 학습한 “오답들 사이의 미묘한 확률 구조”를 사용하지 못한다.

### 4. Mixture of Experts / specialist 구조의 실용성 문제

- Mixture of Experts처럼 여러 expert 모델을 두고 gating으로 라우팅하는 방식은 powerful 하지만 대규모 병렬화, 구현이 어렵고 매우 큰 데이터셋(JFT)을 다루기엔 **시스템적으로 복잡하다**.

### 5. 기존 speech distillation 연구의 한계

- 온도  $T=1$ , unlabeled data 사용, teacher 분포를 단순 모사하는 형태로, 이 논문에서 제안한 방법에 비해 성능 격차를 충분히 줄이지 못한다.

## 논문의 contributions

### 1. 온도 기반 Softmax를 이용한 일반적인 지식 증류 프레임워크 제안

- teacher와 student 모두 softmax with temperature  $T$ 를 사용하고, 높은  $T$ 에서 teacher가 내는 soft한 확률 분포(soft targets)를 student가 그대로 모방하도록 학습하는 지식 증류(distillation) 방법을 제안
- 실제 추론 시에는 student가  $T=1$ 을 사용하므로, 추론은 일반적인 softmax처럼 빠르면서 학습 과정에서는 teacher의 풍부한 구조 정보를 활용한다.

### 2. Soft target + Hard label을 함께 사용하는 학습 목적함수 설계

- 라벨이 있는 경우, 손실 함수를

- (1) 높은 T에서의 soft target에 대한 cross-entropy
  - (2) T=1에서의 hard label에 대한 cross-entropy
- 의 가중합으로 두는 방식을 제안.
- soft target의 gradient가  $1/T^2$ 에 비례하는 점을 분석하고,  $T^2$ 를 곱해 두 손실 기여도를 안정적으로 조절하는 트릭까지 제안.
3. Logit matching이 “고온도 증류”의 특수한 경우임을 이론적으로 증명
- teacher logit  $v_i$ , student logit  $z_i$ 일 때, 높은 온도 T에서의 증류 loss의 gradient를 전개하면  $\propto (z_i - v_i)$  꼴이 되어 제곱 오차로 logit matching하는 것과 동일해짐을 보여줌.
  - Caruana식 logit matching = distillation의 한계 케이스라는 해석을 제공  
→ 기존 model compression 방법을 더 큰 이론 틀 안에 포함시킴.
4. MNIST, 음성 인식, JFT 등 다양한 규모의 실험으로 distillation 효과 입증
5. Specialist 네트워크 구성 및 결합 방법 제안
- generalist의 예측값 공분산을 클러스터링하여 클래스 그룹을 만들고, 각 그룹에 대해 specialist를 학습하는 방법을 제안.
  - 추론 단계에서 generalist + 관련 specialist들의 출력 분포와의 KL divergence 합을 최소화하는 일관된 최종 분포를 gradient descent로 구하는 방법을 제안.
  - Mixture of Experts와 달리 specialist들을 완전히 독립적으로, 병렬로 학습할 수 있고, 이후 하나의 통합 분포로 결합하는 일반적 방법을 제공

## 2. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가  
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가  
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

### 3.1 Core Distillation Framework

- teacher와 student 모두 온도 T를 가진 softmax 출력을 사용한다

$$q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

T가 커질수록 분포가 부드러워져(soft) 클래스들 사이의 상대적 구조 정보가 더 많이 드러난다.

- Soft target
  - transfer set의 각 샘플에 대해, teacher가 높은 온도 T에서 softmax 확률 분포를 출력하면, student는 같은 T로 이 soft 확률분포를 모방하도록 학습된다. 학습이 끝나면 student는 T=1로 추론한다.
- Soft + Hard label 혼합 학습:
  - 목적함수 =
    1. 높은 T에서 계산한 soft target에 대한 cross-entropy
    2. T=1에서 계산한 hard label에 대한 cross-entropy의 가중합
  - soft target으로부터 오는 gradient는 크기가  $1/T^2$ 에 비례하므로, 온도가 바뀌어도 두 손실의 비중이 크게 변하지 않도록 soft 손실 쪽 gradient에  $T^2$ 를 곱해준다.

### 3.2 Logit Matching as a Special Case

- teacher logit  $v_i$ , student logit  $z_i$ 라 할 때, 온도 T에서의 증류 손실은 teacher soft target  $p_i$ 와 student 분포  $q_i$  사이의 cross-entropy이고, 그 gradient는 다음과 같이 주어진다.

$$\frac{\partial C}{\partial z_i} = \frac{1}{T}(q_i - p_i)$$

- 고온도 한계에서 (모든 logit이 T에 비해 작고, 각 샘플마다 logit의 평균을 0으로 맞추는 경우) 이 gradient는 다음과 같이 근사된다.

$$\frac{\partial C}{\partial z_i} \approx \frac{1}{NT^2}(z_i - v_i)$$

- 이는  $(z_i - v_i)^2$ 를 최소화하는 것과 같다. 즉, logit matching은 고온도 증류의 특수한 경우임을 보인다.
- 중간 수준의 T에서는 매우 음수인 logit들의 영향이 줄어들어, 학습 시 거의 제약받지 않은 노이즈성 logit에 과도하게 맞추지 않으면서도 중요한 클래스들 간의 구조는 유지할 수 있다.

### 3.3 Specialist Ensemble Construction

- JFT처럼 (100M 이미지, 15,000 클래스) 매우 큰 데이터셋에서 많은 풀 모델을 앙상블로 학습하는 것은 계산량이 과도하다. 대신, 전체 클래스를 다루는 **generalist** 모델 1개와 혼동되는 일부 클래스들에만 집중하는 여러 개의 **specialist** 모델로 구성된 앙상블을 제안한다.
- 각 **specialist**는
  - **generalist**의 가중치를 초기값으로 사용해 하위 표현을 공유하고,
  - 자신의 특화 클래스들 + 나머지를 합친 **dustbin** 클래스로 구성된 작은 **softmax**를 가지며,
  - 학습 시 절반은 특화 클래스, 절반은 나머지 데이터로 학습한 뒤,
  - **oversampling** 효과를 보정하기 위해 **dustbin** logit에 상수 보정값을 더한다.
- **specialist**에 할당할 클래스 그룹은, **generalist**가 산출한 예측값들의 공분산 행렬의 열들을 클러스터링하여 얻는다. 이는 정답 라벨 없이도, 함께 자주 예측되는 클래스들을 모아 **specialist**의 타깃 집합으로 사용할 수 있게 한다.
- 추론 시에는
  1. **generalist**가 top-n 클래스를 선택하고,
  2. 이들 중 하나 이상을 포함하는 **specialist**들을 **active set**으로 모은 뒤,
  3. **generalist** 분포  $p_g$ 와 **active specialist** 분포들  $p_m$ 과의 KL divergence 합을 최소화하는 전체 클래스 분포  $q$ 를, **softmax** logit에 대해 **gradient descent**로 찾는다.

### 3. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가  
제안 방법의 차별성을 어떻게 표현하고 있는가

- **앙상블 기반 모델 압축**: Buciluă–Caruana–Niculescu-Mizil은 **앙상블의 예측값**을 정답으로 삼아 작은 모델을 학습함으로써 앙상블의 지식을 단일 모델로 압축할 수 있음을 보였다. 이 논문은 여기에 **softmax 온도 조절**을 도입해 보다 일반적인 “증류” 방법을 제시하고, logit 매칭이 그 특수한 경우임을 수식으로 보여준다.
- **드롭아웃 = 암묵적 앙상블**: 드롭아웃은 파라미터를 공유하는 매우 많은 얇은 네트워크들의 앙상블로 해석될 수 있고, 이들 전체를 대표하는 하나의 큰 네트워크를 **teacher**로 사용할 수 있다.

- **대형 음성 모델 → 소형 모델:** Li 등(2014)은 큰 음성 인식 모델의 출력 분포를 작은 모델이 따라가도록 학습하는 유사한 아이디어를 사용하지만, **온도 1, 대규모 비라벨 데이터**에 의존하며, 성능 격차를 줄이는 정도가 이 논문의 방법보다 작다고 보고된다.
- **Mixtures of Experts와의 관계:** 전통적인 Mixture of Experts는 gating 네트워크가 각 예제를 어떤 expert에게 보낼지 학습하는 구조이지만, 이 방식은 대규모 병렬화가 어렵다. 반면 이 논문의 "specialist" 네트워크들은 **generalist 모델을 먼저 학습한 뒤**, 그 혼동 구조를 기반으로 **완전히 독립적으로 병렬 학습**될 수 있다.

## 4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

### 4.1 MNIST

- teacher: 은닉층 1200 ReLU 두 층, 드롭아웃과 가중치 제약, 입력 이미지의  $\pm 2$ 픽셀 jittering을 사용한 큰 네트워크로, MNIST에서 **테스트 오류 67개**를 달성한다.
- 작은 baseline: 은닉층 800 ReLU 두 층, 정규화 없이 hard label만으로 학습하면 **테스트 오류 146개**.
- 같은 구조의 student를 teacher의 **온도  $T=20$  soft target**(및 일부 hard label)으로 증류 학습하면 **테스트 오류 74개**로, 작은 baseline보다 훨씬 teacher에 가까운 성능을 얻는다.
- 온도 영향: 층당 300개 이상 유닛이면  $T \geq 8$ 이면 비슷한 결과지만, 층당 30개처럼 매우 작은 네트워크에서는  $T \approx 2.5-4$ 의 **중간 온도**가 가장 좋았다. 이는 너무 큰  $T$ 에서 매우 음수인 logit 정보를 거의 버리는 것이, 용량이 작은 모델에는 오히려 손해일 수 있음을 시사한다.
- **클래스를 아예 안 보여준 실험(3 제외):**
  - transfer set에서 3을 완전히 제거해도 증류된 모델은 처음에 **206개** 오류(그 중 133개가 3),
  - 3 클래스의 bias를 +3.5만큼 올리면 전체 오류 **109개**, 이 중 3에 대한 오류는 14개 → **학습 중 3을 본 적이 없음에도 3에 대해 98.6% 정확도**를 보인다.
  - transfer set이 7과 8만 포함해도 bias 조정만으로 오류율을 크게 낮출 수 있음을 보인다.

### 4.2 Speech Recognition (Acoustic Models)

- 과제: 대규모 음성 인식을 위한 DNN 기반 **음향 모델** (Android voice search와 유사).
  - 구조: 은닉층 8개, 층당 2560 ReLU, 출력층 softmax 14,000개 HMM 상태.
  - 입력: 40차 Mel filterbank 특징 26프레임(10ms 간격)을 넣고, 21번째 프레임의 상태를 예측.
  - 파라미터 약 8,500만 개, 2000시간(7억 프레임) 음성 데이터 → baseline frame accuracy **58.9%**, WER **10.9%**.
- 동일 구조의 모델을 초기값만 다르게 해서 **10개 학습**한 앙상블은 frame accuracy **61.1%**, WER 10.7%로 성능이 향상된다.
- 이 10개 모델 앙상블의 soft target으로 동일 구조의 single 모델을 증류하면, frame accuracy **60.8%**, WER 10.7%를 얻어, **앙상블이 baseline 대비 얻은 이득의 80% 이상을 단일 모델로 회수**한다

#### 4.3 Soft Targets as Regularizers (Data Efficiency)

- 전체 데이터의 **3%만 사용**해 acoustic 모델을 학습하는 실험:
  - hard target만 사용: train 67.3%, test 44.5%로 심각한 overfitting(early stopping 필요).
  - soft target 사용(teacher는 전체 데이터로 학습): train 65.4%, test 57.0%로, 전체 데이터(58.9%)와 거의 비슷한 성능을 달성한다.
- 이는 soft target이 전체 데이터에서 학습된 **규칙성과 구조를 강하게 내포**하고 있어, 일부 데이터만 가지고도 일반화를 잘 하게 만드는 **강력한 정규화 효과**를 보여준다.

#### 4.4 JFT Specialists

- 데이터셋: Google 내부 JFT (이미지 1억 장, 라벨 1.5만 개). baseline은 수개월 동안 대규모 분산 학습을 거친 깊은 CNN이다.
- baseline generalist를 초기값으로, 약 300개 클래스 + dustbin 클래스를 갖는 **specialist 61개**를 독립적으로 병렬 학습한다.
- 결과(Top-1 정확도):
  - baseline: 조건부 정확도 43.1%, 전체 정확도 25.0%.
  - specialist 61개 추가 시: 조건부 45.9%, 전체 26.1%로, **전체 정확도 기준 약 4.4% 상대 향상**.
  - 하나의 클래스에 대해 specialist가 많이 겹칠수록 상대적인 향상이 커지며, 여러 specialist의 중첩이 유리함을 보여준다.

## 5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- 지식 증류(distillation)는 큰 앙상블이나 강하게 정규화된 teacher 모델의 지식을 작은 student 모델로 옮겨, 단일 모델의 효율성을 유지하면서도 앙상블의 성능 이득 대부분을 회수할 수 있는 방법임을 보인다.
- MNIST에서는 transfer set에 특정 숫자가 아예 없어도, soft target으로 학습한 뒤 bias만 조정하면 그 숫자에 대해 매우 높은 정확도를 얻을 수 있다. 이는 soft target이 클래스 간 유사도 구조를 풍부하게 담고 있음을 보여준다.
- 음성 인식에서는 baseline과 같은 크기의 단일 모델이 10개 앙상블이 제공하는 정확도 향상의 대부분을 증류를 통해 가져올 수 있고, soft target은 3% 데이터만 사용해도 좋은 일반화를 만드는 강력한 정규화 수단이 된다.
- 초대형 비전 과제(JFT)에서는 enormous generalist 네트워크 위에 specialist ensemble을 추가해 성능을 끌어올릴 수 있으며, 각 specialist는 빠르고 독립적으로 병렬 학습할 수 있다. 향후 과제로, 이 specialist들의 지식을 다시 단일 모델로 역증류(distill back)하는 방향이 제안된다.